

요구사항 명세서

과제명	유튜브 테크 리뷰 종합 분석 에이전트
팀명	모아봄
팀장(학번)	김유현 (12214168)
팀원(학번)	김재현 (12214170), 한상민 (12214206)

1. 과제 개요

■ 배경 (기존 문제)

유튜브 리뷰 영상은 추천 알고리즘과 익숙한 채널 중심으로 소비되기 때문에, 소비자가 접하는 정보는 **특정 리뷰어나 채널에 편향**되기 쉽다. 이로 인해 제품에 대한 다양한 관점을 균형 있게 파악하지 못하는 단점이 있다. 또한 여러 유튜버의 의견을 직접 취합하려면 다수의 영상을 개별 시청하고 댓글까지 확인해야 하므로, 구매 의사결정에 앞서 **정보 탐색에 드는 시간**과 노력 비용이 과도하게 증가한다.

■ 문제 해결 목표

LLM을 활용하여 다수의 유튜브 리뷰 영상 자막과 댓글을 자동으로 수집하고 분석함으로써 소비자의 직접 탐색 비용을 줄이고 **정보 취합의 비효율을 해소**한다. 또한 다양한 채널의 리뷰 데이터를 동시에 취합하는 과정에서 LLM이 각 리뷰어의 평가 성향(엄격/관대)을 분석하고 이를 보정한 종합 평가를 생성함으로써 **편향성 문제를 해소**한다. 최종적으로 제품 단위의 장단점, 핵심 이슈, 댓글 감성 반응, 경쟁 제품 비교를 구조화된 리포트로 제공하여, 소비자가 빠르고 합리적인 구매 의사결정을 내릴 수 있도록 지원한다.

■ 기여

본 시스템은 LangChain Agent 기반의 자율적 워크플로우 구조로 설계되어, 데이터 수집, 분류, 분석, 리포트 생성까지의 **전 과정을 에이전트가 자율적으로** 수행한다. 사용자는 제품명 입력 및 분석 영상 선택 (Auto/Custom)이라는 최소한의 조작만으로 구조화된 분석 가이드를 제공받으며, 객관적이고 균형 잡힌 정보를 바탕으로 구매 판단을 내릴 수 있다. 웹 서비스 형태로 배포되어 별도의 설치 없이 누구나 접근 가능하며, 향후 타 제품군 및 멀티채널 리뷰 분석 플랫폼으로의 확장도 고려한다.

2. 시스템 개요

■ 전체 시스템 흐름

사용자 입력 → 리뷰 영상 후보 수집 → 텍스트 전처리 → AI 분석 파이프라인 → 분석 결과 제공

■ 단계별 설명

- 사용자 입력: 제품명 입력 및 분석 조건 설정 (Auto / Custom 영상 선택 방식 선택)
- 리뷰 영상 후보 수집: YouTube Data API 기반 자동 검색. 메타데이터 / 영상 자막 / 영상 요약 정보 /

댓글 데이터 4종 수집

- ③ 텍스트 전처리: 불용어 제거 / 정규화 / 광고 문구 제거 / 댓글 3단계 필터링 (규칙 기반 → LLM Few-shot 분류 → Agent 분기)
- ④ AI 분석 파이프라인 (LangChain Agent 기반 자율 워크플로우)
 - 리뷰어 성향 분석: 평가 성향(엄격/관대) 분류 및 편향 보정 지표 산출
 - 보고서 ① 생성 (영상 단위 - 자막 기반): 제품에 대한 리뷰어의 평가 내용 중심 보고서
 - 보고서 ② 생성 (영상 단위 - 댓글 기반): 소비자 반응 및 감성 분석 결과 보고서
 - 보고서 ③ 생성 (영상 단위 - 자막+댓글 종합): 위 두 보고서를 통합한 영상 단위 종합 보고서 (영상 n개 → 보고서 ①②③ 각 n개 생성)
 - 보고서 ④ 생성 (제품 단위 - 전체 종합): 복수 영상 자막 전체 + RAG 추출 핵심 댓글 + 감성 라벨 + 리뷰어 성향을 종합한 최종 제품 분석 리포트
- ⑤ 분석 결과 제공: 유튜버별 보고서 / 통합 리포트 / 경쟁 제품 추천 (웹 UI 대시보드)

■ 기술 스택

- 프론트엔드: React, TypeScript
- 백엔드: FastAPI (Python)
- DB: PostgreSQL, Redis, VectorDB
- AI: LLM (Gemini API), LangChain Agent, scikit-learn, Transformers
- 데이터 수집: YouTube Data API
- MLOps: Airflow, ELK

3. 기능 요구사항

[사용자]

요구사항 ID	FR-001
요구사항명	회원가입
설명	비밀번호, 닉네임, 생년월일, 성별을 입력하여 회원가입한다. 필수 항목 미입력 시 에러 메시지를 표시한다.
검증 기준	필수 항목 미입력 시 에러 메시지 정상 표시 확인
관련 기술	Firebase Auth, FastAPI
비고	비밀번호 4자 이상

요구사항 ID	FR-002
요구사항명	SNS 로그인
설명	구글 계정으로 소셜 로그인(OAuth 2.0)을 지원한다.
검증 기준	구글 로그인 후 3초 이내 메인 화면 진입 확인

관련 기술	OAuth 2.0
비고	

[제품 탐색]

요구사항 ID	FR-003
요구사항명	제품 검색
설명	사용자가 제품명 또는 키워드를 입력하면 사전에 구축한 제품 DB를 기반으로 일치/유사한 제품 후보를 제시한다.
검증 기준	정확한 제품명, 일부 키워드, 오타자 입력 상황에서 관련 제품 후보가 정상 노출되고, 선택한 제품이 분석 화면으로 올바르게 연결됨
관련 기술	PostgreSQL, FastAPI, React, pg_trgm
비고	사전 구축 제품 DB 기반

요구사항 ID	FR-004
요구사항명	제품 정보 제공
설명	사전에 구축한 DB에서 브랜드, 모델명, 출시일, 주요사양 등 제품 정보를 조회하여 출력한다.
검증 기준	검색한 제품의 기본 정보와 주요 사양이 누락 없이 표시됨
관련 기술	PostgreSQL, FastAPI
비고	사전 구축 제품 DB 기반

요구사항 ID	FR-005
요구사항명	분석 대상 영상 선택
설명	제품 종합 분석에 활용할 유튜브 영상 후보군(미리 설정된 필터링 기준으로 정제하여 제공)을 사용자가 선택하거나, AI 자동 선택 옵션을 제공한다. Auto(AI 자동 선정) / Custom(사용자 직접 선택) 방식 중 하나를 선택하여 분석 대상 영상을 결정한다.
검증 기준	관련 영상 후보 목록이 정상 노출되고, 두 방식 모두에서 분석 대상 영상이 3개 이상 확정되어 분석 파이프라인으로 정상 전달됨
관련 기술	YouTube Data API, FastAPI, React, LLM/Rule-based Filtering
비고	Auto vs Custom 구조

요구사항 ID	FR-006
---------	--------

요구사항명	분석 진행 상태 표시
설명	LLM 파이프라인 실행 중 현재 처리 단계(자막 수집 / 전처리 / 분석 / 리포트 생성)를 사용자에게 실시간 표시하고, 예상 소요 시간을 안내한다.
검증 기준	분석 시작 후 각 단계 전환 시 UI에 현재 단계명이 표시되고, 완료 시 결과 화면으로 자동 전환됨
관련 기술	React, FastAPI, WebSocket 또는 SSE
비고	

[데이터 수집]

요구사항 ID	FR-007
요구사항명	영상 자막 수집
설명	분석 요청 시점에 선택된 영상의 자막을 YouTube API로 실시간 수집하고, 사전 배치로도 수집하여 DB에 저장한다.
검증 기준	선택된 영상의 자막 데이터가 누락 없이 텍스트 형태로 확보되어 DB에 저장됨
관련 기술	YouTube Data API
비고	실시간 수집 및 배치 사전 수집 모두 포함

요구사항 ID	FR-008
요구사항명	댓글 수집 및 1차 필터링
설명	YouTube Data API로 댓글을 수집한 뒤, 글자 수 미달, 이모지 과다, 광고성/단순 반응 댓글을 정규식/stopword 사전 기반으로 1차 제거한다.
검증 기준	수집된 댓글에서 광고성/단순 반응 댓글이 분석 대상에서 제외됨
관련 기술	YouTube Data API, Python, Regex

비고	
----	--

[전처리]

요구사항 ID	FR-009
요구사항명	텍스트 전처리
설명	수집된 자막 및 댓글에서 불용어 제거, 반복 문자 정규화, 광고 문구 제거 등의 전처리를 수행한다.
검증 기준	전처리 후 불필요 데이터가 제거되고 분석 모델 입력 형식에 맞게 변환됨
관련 기술	Python, KoNLPy, Regex
비고	

요구사항 ID	FR-010
요구사항명	2차 LLM 기반 댓글 분류
설명	1차 필터링을 통과한 댓글을 LLM Few-shot으로 클래스 분류한다. 분류 클래스: 제품 평가 의견 / 제품 관련 질문 / 영상,유튜버 반응 / 잡담,밈 / 무관 댓글.
검증 기준	댓글별 분류 라벨이 자동 부여되어 저장됨
관련 기술	LLM
비고	

요구사항 ID	FR-011
요구사항명	3차 Agent 기반 댓글 활용 결정
설명	2차 LLM 분류 결과에 따라 Agent가 '제품 평가 의견'은 분석에 사용, '제품 관련 질문'은 보조 저장, 나머지는 제외로 분기한다. 확신도가 낮은 댓글은 재분류 처리한다.
검증 기준	댓글이 분석 사용 / 보조 저장 / 제외로 올바르게 분기됨
관련 기술	LangChain Agent
비고	

요구사항 ID	FR-012
요구사항명	댓글 감성 분류
설명	분석 대상으로 선별된 댓글(제품 평가 의견)에 감성 분석 모델을 적용하여 긍정/중립/부정 라벨을 부여한다.

검증 기준	제품 평가 의견 댓글에 감성 라벨이 부여되어 저장됨; 감성 분류 F1-score 0.75 이상 유지 (샘플 테스트셋 기준)
관련 기술	scikit-learn, Transformers
비고	F1-score 0.75 기준

요구사항 ID	FR-013
요구사항명	자막 청크 분할 및 벡터 임베딩 저장
설명	자막 텍스트를 RAG 처리에 적합한 단위 길이로 청크 분할한 뒤, 각 청크를 벡터로 변환하여 벡터 DB에 저장한다.
검증 기준	설정 길이 기준으로 청크 분할이 완료되고 각 청크의 임베딩이 생성되어 벡터 DB에 정상 저장 및 조회 가능함을 확인
관련 기술	Embedding Model, VectorDB
비고	

요구사항 ID	FR-014
요구사항명	리뷰어 성향 분석
설명	각 영상의 자막과 평가 표현을 분석하여 리뷰어별 평가 성향(엄격/관대)을 분류하고, 이후 종합 리포트 해석 시 편향 보정 지표로 반영한다.
검증 기준	리뷰어별 평가 성향(엄격/관대)이 일관된 기준으로 분류됨
관련 기술	LLM, 통계 분석
비고	편향 보정 핵심 기능

[보고서 생성 – 영상 단위]

요구사항 ID	FR-015
요구사항명	보고서 ① – 영상 단위 자막 기반 리뷰 보고서
설명	각 영상의 자막을 LLM에 입력하여, 해당 영상(리뷰어)이 제품에 대해 평가한 내용(주요 장단점, 강조 스펙, 사용 경험 등)을 중심으로 영상 단위의 제품 평가 보고서를 생성한다. 보고서 내 핵심 주장은 자막 텍스트 내 근거에 기반해야 한다.
검증 기준	각 영상별로 해당 제품에 대한 평가 내용(장단점, 강조 스펙, 사용 경험)이 누락 없이 포함된 보고서가 생성됨; 핵심 주장의 자막 내 근거 존재 확인 (Hallucination 방지)
관련 기술	LLM (Gemini, Groq-Llama, etc)
비고	

요구사항 ID	FR-016
요구사항명	보고서 ② – 영상 단위 댓글 기반 소비자 반응 보고서
설명	필터링/감성 분류가 완료된 댓글을 LLM에 입력하여 해당 영상에 대한 소비자 반응 보고서를 생성한다. 긍정/부정/주요 반응이 포함된 형태로 구성한다.
검증 기준	긍정/부정/주요 반응이 포함된 보고서가 생성됨
관련 기술	LLM
비고	

요구사항 ID	FR-017
요구사항명	보고서 ③ – 영상 단위 자막+댓글 종합 보고서
설명	자막 기반 보고서①과 agent(3단계)를 통해 선택된 댓글(클래스 라벨, 감성분석 라벨)을 함께 활용하여 영상 단위 종합 보고서를 생성한다. 영상이 n개인 경우 보고서 ①②③은 각각 n개 생성된다.
검증 기준	자막과 댓글, 두 정보가 통합된 종합 보고서가 출력됨
관련 기술	LLM
비고	

[보고서 생성 – 제품 단위]

요구사항 ID	FR-018
요구사항명	보고서 ④ – 제품 단위 종합 보고서 (RAG 기반)
설명	복수 영상의 자막 전체와 RAG로 추출한 핵심 댓글(클래스 라벨&감성 라벨), 리뷰어 성향 분석 결과를 LLM에 입력하여 제품 단위의 최종 종합 보고서를 생성한다. 보고서에는 제품의 종합 장단점/핵심 이슈/소비자 반응/리뷰어별 성향 보정 결과가 포함된다. 보고서 내 핵심 주장은 수집된 자막 또는 댓글 텍스트 내 근거에 기반해야 한다.
검증 기준	자막/핵심 댓글(클래스라벨&감성 라벨)/리뷰어 성향이 반영된 제품 단위 보고서가 생성됨; 샘플 보고서 5건 이상에 대해 검수자 2인이 주요 주장의 근거 존재 여부 확인, 근거 없는 주장 비율 10% 이하
관련 기술	LLM, RAG, VectorDB
비고	최종 핵심 결과물

요구사항 ID	FR-019
요구사항명	경쟁 제품 비교 및 추천
설명	분석된 제품과 유사한 경쟁 제품을 자동으로 추천하고 주요 차이점을 비교하여 제공한다.

검증 기준	유사 제품이 최소 3개 이상 추천되고 비교 정보가 제공됨
관련 기술	RAG, 추천 알고리즘
비고	

[시스템]

요구사항 ID	FR-020
요구사항명	분석 결과 재활용 및 PDF 다운로드
설명	동일 제품에 대해 이미 수행된 분석 결과가 DB에 존재할 경우, 전체 파이프라인 재실행 없이 캐시된 보고서를 반환한다. 분석 결과 PDF 다운로드를 지원한다.
검증 기준	캐시 결과 반환 시 2초 이내 응답; 분석 결과 PDF 다운로드 가능
관련 기술	PostgreSQL, Redis, FastAPI
비고	비용 절감과 직결

요구사항 ID	FR-021
요구사항명	YouTube API Quota 초과 처리
설명	YouTube Data API 일일 할당량(기본 10,000 units) 소진 시, 사용자에게 안내 메시지를 표시 하고 다음 갱신 시각을 안내한다.
검증 기준	Quota 초과 시 에러 노출 없이 안내 메시지 표시; 캐시 데이터 대체 제공 또는 예상 복구 시각 안내가 정상 동작함을 확인
관련 기술	YouTube Data API, FastAPI, Redis
비고	Quota 기본 10,000 units/day

요구사항 ID	FR-022
요구사항명	분석 대상 영상 수 제한
설명	1회 분석 요청 시 처리할 수 있는 영상 수의 상한을 최대 10개로 설정하여 LLM 토큰 비용 및 처리 시간을 제어한다. 사용자에게 적용 기준을 UI에 안내한다.
검증 기준	10개 초과 영상 선택 시 경고 메시지 표시 및 상한 적용; 상한 내에서 분석이 정상 완료됨을 확인
관련 기술	FastAPI, React
비고	비용 및 응답시간 통제 목적

요구사항 ID	FR-023
---------	--------

요구사항명	제품 정보 DB 관리
설명	서비스 대상 제품 정보를 DB에 등록하고 검색 시 조회한다. 신규 영상 및 댓글 데이터를 기존 DB와 충돌 없이 주기적으로 갱신한다.
검증 기준	신규 제품 등록 및 기존 정보 수정 후 서비스 화면에 반영됨; 데이터 갱신 시 기존 데이터와 충돌 없이 업데이트됨
관련 기술	PostgreSQL, FastAPI
비고	

요구사항 ID	FR-024
요구사항명	데이터 품질 관리
설명	수집 데이터의 중복을 탐지/제거하고 오류 데이터를 식별하여 품질을 유지한다.
검증 기준	중복 데이터 제거 및 오류 데이터 비율 감소 확인
관련 기술	-
비고	

요구사항 ID	FR-025
요구사항명	로그 모니터링
설명	AI 파이프라인 실행 중 발생하는 오류 및 예외 상황을 로그로 기록하고 관리자가 확인할 수 있도록 한다.
검증 기준	오류 발생 시 로그가 기록되고 관리자 확인 가능
관련 기술	ELK, Logging
비고	

4. AI/ML 요구사항

4.1 모델 사양

항목	내용
모델 아키텍처	1. LLM API 기반 요약·키워드 추출·리포트 생성 모듈 2. Transformer 기반 텍스트 감성/의견 분류 모델 3. RAG 적용을 위한 임베딩 모델 및 벡터 검색 모듈 4. vLLM 기반 로컬/서버 환경의 LLM 추론 및 서빙 모듈
선택 근거	1. LLM API: 한국어 지원 및 긴 문맥 처리에 적합한 LLM 활용 2. Transformers: 리뷰/댓글의 감성 및 의견 유형 분류를 위한 분류 모델 파인튜닝

	닝 가능 3. RAG: 검색 기반 근거 제공을 통해 환각을 줄이고 근거 기반 응답 생성 지원 4. vLLM을 활용하여 대규모 언어모델을 효율적으로 서빙하고, 다중 사용자 요청에도 안정적인 추론 응답을 제공 가능
프레임워크	Python, LangChain, Hugging Face Transformers, scikit-learn, vLLM

4.2 데이터 요구사항

항목	내용
데이터 출처	YouTube Data API (영상 메타데이터, 자막, 댓글) / YouTube Comments Dataset (Kaggle: atifaliak/youtube-comments-dataset, 감성 분석 모델 학습용)
데이터 규모	YouTube 검색 결과 기반 수집 (제품당 최대 10개 영상 분석) 감성 분석 학습용: Kaggle 데이터셋 활용
라벨링 방식	댓글 분류: LLM Few-shot 자동 라벨링 감성 분석: Kaggle 기존 라벨 활용 (별도 수동 라벨링 없음)
전처리	불용어 제거, 반복 문자 정규화, 광고성 문구 제거 (Regex, KoNLPy) / 자막 청크 분할 후 벡터 임베딩 변환 / 댓글 3단계 필터링 파이프라인 (규칙 기반 → LLM 분류 → Agent 분기)

5. 비기능 요구사항

※ 기능이 얼마나 잘 동작해야 하는지에 대한 요구사항.

ID	분류	요구사항	검증 기준
NR-001	성능	제품 분석 요청 시 최초 파이프라인 실행의 평균 응답 시간이 60초 이내여야 한다.	최초 분석 평균 응답 시간 60초 이내; 캐시 결과 반환 시 2초 이내
NR-002	성능	제품 검색 요청 후 1초 이내 결과 목록이 출력되어야 한다.	제품 검색 요청 후 1초 이내 결과 목록 출력 확인
NR-003	성능	동시 5명 이상의 분석 요청 시 각 요청이 오류 없이 정상 처리되고 응답 시간 기준을 유지해야 한다.	동시 5명 이상 분석 요청 시 오류 없이 정상 처리 및 응답 시간 기준 유지 확인
NR-004	정확도	LLM이 생성한 보고서 내 핵심 주장은 수집된 자막 또는 댓글 텍스트 내에 근거가 있어야 하며, 근거 없는 정보가 포함되지 않아야 한다 (Hallucination 최소화).	샘플 보고서 5건 이상에 대해 검수자 2인이 주요 주장의 근거 존재 여부 확인; 근거 없는 주장 비율 10% 이하
NR-005	정확도	감성 분석 모델의 분류 F1-score가 0.75	샘플 테스트셋 기준 감성 분류 F1-score

		이상이어야 한다.	0.75 이상 유지
NR-006	사용성	사용자가 최소 단계로 원하는 분석 결과에 도달할 수 있어야 한다.	기능 접근 단계 수 측정 및 기준 충족 확인
NR-007	확장성	AI 모델을 변경하거나 추가할 수 있는 구조를 유지해야 한다.	모델 교체 시 기존 시스템 수정 최소화 확인
NR-008	확장성	새로운 데이터 소스 추가 시 유연하게 확장 가능해야 한다.	신규 데이터 소스 연동 테스트
NR-009	안정성	API 오류 및 데이터 수집 실패 시 안정적으로 처리해야 한다.	에러 발생 시 재시도 또는 예외 처리 동작 확인
NR-010	보안	외부 API 키 및 민감 정보는 환경 변수 또는 보안 저장 방식으로 안전하게 관리해야 한다.	환경 변수 또는 보안 저장 방식 적용 확인
NR-011	보안	회원가입 시 수집되는 개인정보는 암호화하여 저장하고 제3자에게 제공하지 않는다. 비밀번호는 bcrypt 단방향 해시로 저장한다.	비밀번호 bcrypt 해시 저장 확인; 개인정보 컬럼 암호화 적용 확인; 민감 정보가 API 응답에 노출되지 않음을 확인
NR-012	유지보수성	기능별로 코드가 분리되어 유지보수가 용이해야 한다.	모듈 단위 수정 시 다른 기능 영향 최소화 확인
NR-013	호환성	주요 웹 브라우저(Chrome)에서 서비스가 정상 동작해야 한다.	Chrome 환경에서 UI 및 기능 정상 작동 확인
NR-014	비용	API, 토큰 사용량 및 서버 비용이 예산 범위 내에 유지되어야 한다.	월별 비용 로그 기준 예산 초과 여부 확인
NR-015	운영 환경	MVP 기준 단일 서버 환경에서 동시 5명 이상의 사용자 요청을 처리할 수 있는 배포 환경을 구성한다. 클라우드(GCP/AWS) 또는 로컬 서버 중 하나로 환경을 확정한다.	배포 환경이 문서에 명시되고, 해당 환경에서 동시 5명 기준 분석 요청이 오류 없이 처리됨을 확인